

Prédiction de l'intention d'achat en e-commerce

Étude comparative des méthodes de classification automatique

Yannick ASSI Guillaume COULON

Université Catholique de l'Ouest
Master MIASHS – Ingénierie de la donnée et actuariat-finance

Février 2026

Encadrante : Nisrine DOUMIATI JRAD

Contexte et objectif

- Le e-commerce génère une grande quantité de données de navigation : pages consultées, durées, taux de rebond, provenance du trafic, type de visiteur.
- L'enjeu est de prédire si une session utilisateur aboutira à un achat ou non.
- Il s'agit d'un problème de **classification supervisée binaire**.

Objectif du projet

Comparer plusieurs méthodes de classification afin d'identifier le modèle le plus adapté à la prédiction de la variable Revenu :

$$\text{Revenu} = \begin{cases} 1 & \text{si achat} \\ 0 & \text{sinon} \end{cases}$$

Présentation du jeu de données

- Base de données : **12 330 observations**
- Variable cible : **Revenue**
- Répartition des classes :
 - **85%** de non-acheteurs
 - **15%** d'acheteurs
- Base déséquilibrée : difficulté supplémentaire pour détecter la classe minoritaire

Exemples de variables :

- Navigation : Administrative, Informational, ProductRelated
- Durées : Administrative_Duration, ProductRelated_Duration
- Comportement : BounceRates, ExitRates, PageValues
- Contexte : Month, VisitorType, Weekend

Préparation des données

- Transformation des variables qualitatives en variables numériques :
 - Month
 - VisitorType
 - Weekend
- Détection et filtrage de valeurs extrêmes (quantile 0.99)
- Normalisation des variables quantitatives
- Réduction de la base de 12 330 à **11 768 observations**
- Séparation aléatoire :
 - **80%** apprentissage
 - **20%** test

Point d'attention

Le déséquilibre entre acheteurs et non-acheteurs influence fortement les performances des modèles.

Méthodes de classification testées

Méthodes étudiées

- LDA
- QDA
- Arbre de décision
- SVM linéaire
- SVM non linéaire
- Réseau de neurones

Critères de comparaison

- Accuracy globale
- Détection des non-acheteurs
- Détection des acheteurs
- Généralisation
- Interprétabilité

Problème métier : en e-commerce, détecter les acheteurs potentiels est souvent plus important que maximiser uniquement l'accuracy globale.

Résultats comparatifs

Méthode	Accuracy	Non-acheteurs	Acheteurs
LDA	$\approx 89\%$	Très bien détectés $\approx 97\%$	Faiblement détectés $\approx 42\%$
QDA	$\approx 82\%$	Bien détectés $\approx 87\%$	Mieux détectés que LDA $\approx 67\%$
Arbre de décision	$\approx 90\%$	Très bien détectés $\approx 94\%$	Bon compromis $\approx 51\%$
SVM linéaire	89%	97%	40%
SVM non linéaire	89%	96%	50%
Réseau de neurones	Très faible	Faible	Très faible

Constat général

La plupart des modèles classent bien les non-acheteurs, mais rencontrent des difficultés sur la classe minoritaire des acheteurs.

- **LDA** : bonne accuracy, modèle stable, mais faible sensibilité sur les acheteurs.
- **QDA** : améliore la détection des acheteurs par rapport à LDA, mais accuracy un peu plus faible.
- **Arbre de décision** : modèle interprétable, met en évidence les variables les plus discriminantes.
- **SVM linéaire** : bon niveau global, mais performance limitée sur la classe minoritaire.
- **SVM non linéaire** : légère amélioration sur les acheteurs, mais plus sensible au surapprentissage selon l'analyse train/test.
- **Réseau de neurones** : performances insuffisantes dans notre implémentation sous R.

Lecture critique

Une accuracy élevée n'est pas suffisante à elle seule : il faut aussi bien détecter les acheteurs potentiels.

Zoom sur l'arbre de décision

- L'arbre de décision fournit des règles directement interprétables.
- Les variables les plus importantes sont :
 - **PageValues**
 - **BounceRates**
 - **ProductRelated_Duration**
 - **Administrative**
 - **Month**

Interprétation métier

Un utilisateur a une probabilité d'achat plus forte lorsque :

- la valeur des pages visitées est élevée ;
- le taux de rebond est faible ;
- l'engagement sur les pages produits est important.

L'arbre relie donc directement les résultats statistiques à une lecture marketing et comportementale.

Discussion des résultats

- Le principal défi du projet est le **déséquilibre des classes**.
- Les modèles apprennent plus facilement à reconnaître les non-acheteurs, largement majoritaires.
- Les acheteurs sont plus difficiles à détecter, alors qu'ils représentent la classe la plus intéressante d'un point de vue métier.
- Le réseau de neurones n'a pas donné de bons résultats dans cette configuration.

Limites

- déséquilibre de la base ;
- sensibilité des modèles à la classe minoritaire ;
- paramétrage perfectible pour certaines méthodes.

Bilan

- Tous les modèles n'ont pas la même capacité à détecter l'intention d'achat.
- Les meilleures accuracy globales sont obtenues par LDA et SVM.
- Toutefois, l'**arbre de décision** apparaît comme le modèle le plus pertinent dans notre cas :
 - résultats satisfaisants,
 - bonne interprétabilité,
 - lecture métier claire des variables clés.

Perspectives

- rééquilibrage des classes (ex. sur-échantillonnage) ;
- optimisation des hyperparamètres ;
- ajout de métriques comme le recall, la précision ou le F1-score.