

PROJET : CLASSIFICATION AUTOMATIQUE

Consignes

Toutes les consignes sont dans la présentation (diapo 9)

La prédiction de l'intention d'achat en e-commerce

Contexte

Dans un contexte où le commerce en ligne ne cesse de croître, comprendre et anticiper le comportement des acheteurs est devenu un enjeu majeur pour les entreprises. Les sites e-commerce disposent d'une quantité massive de données issues des interactions des utilisateurs : pages visitées, temps passé sur le site, taux de rebond, historique d'achats, et bien d'autres paramètres. Exploiter ces informations permet d'optimiser l'expérience utilisateur, d'améliorer les stratégies marketing et d'augmenter les taux de conversion.

La prédiction de l'intention d'achat consiste à identifier, en temps réel, si un visiteur est susceptible de finaliser une transaction ou d'abandonner son parcours d'achat. Ce problème est généralement formulé comme une classification binaire supervisée, où l'objectif est de distinguer les utilisateurs enclins à acheter de ceux qui ne le sont pas.

Les modèles de machine learning sont souvent utilisés pour capturer les séquences d'interactions des utilisateurs. Ces modèles analysent en temps réel les comportements des utilisateurs et permettent aux entreprises de prendre des décisions stratégiques, comme personnaliser les recommandations, ajuster les promotions ou envoyer des notifications ciblées.

Objectifs

Ce projet vise à explorer plusieurs modèles de prédiction de l'intention d'achat des acheteurs en ligne en utilisant des données réelles. Il vise à étudier l'impact des différentes variables sur la décision d'achat et comparer les performances de plusieurs modèles d'apprentissage automatique. Le problème de la prédiction de l'intention d'achat des acheteurs en ligne est formulé comme une classification binaire supervisée. Le jeu de données comprend 12 330 enregistrements de clients ayant adopté différents comportements sur une période d'un an. Parmi ces 12 330 enregistrements, 10 422 (soit 84,5%) sont des exemples négatifs, où les clients n'ont pas finalisé leur achat, tandis que 1 908 enregistrements correspondent à des exemples positifs, où les clients ont complété leur transaction.

L'intention d'achat est à expliquer par différentes variables issues des interactions en temps réel des utilisateurs lors des visites de pages. Ces visites de pages sont classées en administratives ou gestion de compte, et la durée correspondante est mesurée en secondes.

Les variables incluent également des informations sur le nombre de pages visitées et la durée de consultation sur le site d'achat en ligne. Les visites de pages produit et le temps passé sur ces pages sont également pris en compte.

Les valeurs des variables sont collectées en temps réel en fonction des types d'actions des utilisateurs, telles que la consultation de nouvelles pages ou la navigation entre différents types de produits. Les informations de navigation de toutes les pages visitées par l'acheteur sont ensuite transformées en d'autres caractéristiques basées sur les modèles de navigation et les taux de réussite des pages.

De plus, des informations sur le système du client (navigateur, localisation, système d'exploitation, etc.) ainsi que la période de navigation (mois, année, semaine) sont prises en compte.

Une explication détaillée des variables est donnée ci-dessous

Les valeurs des premières 6 variables sont contenues dans l'URL des pages visitées par l'utilisateur et mises à jour en temps réel lorsque celui-ci effectue une action, tel que passer d'une page à une autre.

Administrative Nombre de pages de gestion du compte visitées par l'utilisateur

Administrative_Duration Temps passé par l'utilisateur sur les pages de gestion du compte (en secondes)

Informational Nombre de pages consultées par l'utilisateur contenant des informations générales du site d'achat

Informational_Duration Temps passé par l'utilisateur sur les pages contenant des informations générales du site d'achat

ProductRelated Nombre de pages visitées par l'utilisateur contenant des informations sur des produits ou articles

ProductRelated_Duration Temps passé par l'utilisateur sur les pages liées aux produits ou articles

Les trois variables suivantes sont des indicateurs mesurés par Google Analytics pour chaque page du site e-commerce.

BounceRates Taux de rebond moyen des pages consultées. Le "Taux de Rebond" (Bounce Rate) pour une page web correspond au pourcentage de visiteurs qui accèdent au site via cette page puis le quittent (rebondissent) sans effectuer d'autres actions déclenchant une requête vers le serveur d'analyse au cours de cette session.

ExitRates Valeur moyenne du taux de sortie des pages consultées. Pour une page web spécifique le taux de sortie est calculé comme le pourcentage de consultations de cette page qui ont été les dernières de la session.

PageValues représente la valeur moyenne d'une page web visitée par un utilisateur avant de finaliser une transaction e-commerce.

SpecialDay Proximité temporelle entre le moment de navigation sur le site et un jour spécial. La valeur de cette variable est déterminée en prenant en compte la dynamique du commerce en ligne, comme la durée entre la date de commande et la date de livraison. Par exemple, pour la Saint-Valentin, cette

valeur est non nulle entre le 2 février et le 12 février, nulle avant et après ces dates, sauf si elle est proche d'un autre jour spécial, et atteint sa valeur maximale de 1 le 8 février.

Les variables suivantes sont catégorielles

Month Mois correspondant à la date de navigation (12 modalités)

OperatingSystems Système d'exploitation de l'ordinateur de l'utilisateur (8 modalités)

Browser Navigateur utilisé par l'utilisateur (13 modalités)

Region Localisation géographique depuis laquelle la session de navigation a été initiée par l'utilisateur (9 modalités)

TrafficType Source de trafic par laquelle l'utilisateur a accédé au site d'achat (20 modalités)

VisitorType Trois types possibles pour l'utilisateur : nouveau visiteur, visiteur récurrent et autres (3 modalités)

Weekend Valeur binaire indiquant si le jour de navigation est un week-end ou non (2 modalités)

Revenue Étiquette de classe indiquant si la visite s'est conclue par un achat ou non.

Travail à réaliser

Préparer vos données (analyse des distributions, traitement des valeurs manquantes aberrantes, normalisation, rééchantillonnage)

Pour chaque modèle d'apprentissage supervisé : entraîner, tester et interpréter les résultats.

Comparer et discuter les résultats d'un point de vue variables et mesures de performance.